



Московский государственный университет имени М. В. Ломоносова

Факультет вычислительной математики и кибернетики

Кафедра математических методов прогнозирования

Оптимизация параметров глубокой сети с использованием байесовского подхода

Выпускная квалификационная работа

Студент: Мищук Г. А.

Научный руководитель: Кравцова О. А.

Москва, 2026

Введение

Обучение глубоких нейронных сетей даёт высокую точность во многих прикладных задачах.

Качество модели сильно зависит не только от обучаемых весов, но и от **гиперпараметров**.

Подбор гиперпараметров — отдельная вычислительно дорогая задача.

В работе рассматривается три группы методов подбора гиперпараметров: статистические, **байесовские**, эволюционные.

Постановка задачи подбора гиперпараметров

Подбор гиперпараметров формулируется как двухуровневая задача оптимизации: внешний уровень оптимизирует λ , внутренний — обучает веса θ при фиксированных λ .

Классическая постановка

$$\lambda^* = \arg \min \mathcal{L}_{\text{val}}(\lambda)$$

Каждая оценка целевой функции $\mathcal{L}_{\text{val}}(\lambda)$ требует **полного** обучения модели — обхода всех эпох.

Проверка одной конфигурации дорого; для больших задач — недопустимо дорого.

Многоуровневая постановка

$$\lambda^* = \arg \min \mathcal{L}_{\text{val}}(\lambda, s)$$

Целевая функция расширяется параметром **уровня точности s** — числа эпох обучения. Допускаются **приближённые** оценки на малом числе эпох.

Неперспективные λ отсеиваются на низкой точности; полное обучение остаётся для лучших кандидатов.

В работе рассматривается многоуровневая постановка как наиболее подходящая для задач с большими вычислительными затратами.

Актуальность, цель и задачи работы

Актуальность и цель работы

Существующие сравнения методов подбора гиперпараметров проводятся, как правило, на небольшом числе задач одного типа, а также не учитывают вычислительные затраты, как отдельный критерий качества работы алгоритма. Таким образом, актуальным является разработка методики сравнения методов оптимизации гиперпараметров глубоких сетей с учетом качества, времени и устойчивости результата.

Задачи исследования:

1. Разработка единого воспроизводимого программного комплекса для запуска сравниваемых методов подбора гиперпараметров на рассматриваемых наборах данных.
2. Проведение сравнения методов по итоговому качеству, времени работы и стабильности результата.
3. Проведение статистического анализа значимости различий методов и формулировка условий их применимости.

Сравнительный обзор десяти методов

Метод	Тип	Суррогат	Много- уровн.	Ключевая особенность
Adam (без подбора)	стат.	—	—	стандартные значения гиперпараметров
Случайный поиск	стат.	—	—	равномерное семплирование Λ
Hyperband	стат.	—	✓	Successive Halving — отсев на низкой точности
TPE	байес.	KDE	—	модель $p(\lambda y)$ через ядерное сглаживание
GP-BO	байес.	GP	—	гауссовский процесс + Expected Improvement
BOHB	байес.	KDE	✓	TPE + Hyperband (комбинация)
MFBO	байес.	MF-GP	✓	совместный GP по (λ, s) ; q-Knowledge Gradient
Baseline DE	эвол.	—	—	эволюция напрямую по весам θ (без градиента)
Optuna + DE	эвол.	TPE для h	—	TPE подбирает размер слоя, DE учит веса
DE + DE Hybrid	эвол.	—	—	вложенные циклы DE по λ и по весам

Статистические — без вероятностной модели целевой функции. **Байесовские** — с моделью $p(\lambda | y)$.

Эволюционные — без использования градиента.

Наборы данных и сетка гиперпараметров

Используемые наборы данных

№	Название	Тип задачи	N	Признаки
1	WINE	классификация (3 кл.)	178	13
2	WDBC	классификация (2 кл.)	569	30
3	DIGITS	классификация (10 кл.)	1 797	64
4	ABALONE	регрессия	4 177	8
5	KIN8NM	регрессия	8 192	8
6	Higgs	классификация (2 кл.)	98 050	28
7	Fashion-MNIST	классификация (10 кл.)	60 000	28×28

Пространство гиперпараметров

- **h** — размер скрытого слоя:
 $\in [128, 512]$, целочисленное.
- **lr** — скорость обучения:
 $\in [10^{-4}, 5 \cdot 10^{-3}]$, логравномерное.
- **dropout** — вероятность отключения нейронов:
 $\in [0.0, 0.5]$, равномерное.

Постановка эксперимента

Этапы эксперимента

1. Каждый из семи наборов данных предварительно предобработан (стандартизация, кодирование, разбиение).
2. На каждом наборе и для каждого из десяти методов запущена оптимизация гиперпараметров при пяти фиксированных значениях начального состояния генератора случайности.
3. Для каждого прогона зафиксированы: время работы, число эпох-эквивалентов и накопленный минимум потери на валидации.
4. Итоговое сравнение методов проведено по критерию Фридмана и пост-хок тесту Немея.

Параметры эксперимента

Архитектуры:

- MLP — для табличных задач;
- CNN — для Fashion-MNIST.

Сетка уровней точности:

- {1, 5, 20} эпох — малые;
- {1, 4, 12} эпох — большие.

Бюджет:

- малые задачи — до 20 эпох;
- большие — до 12 эпох.

Начальные состояния:

{42, 123, 2024, 7, 999}.

Итоговое качество

Метод	WINE	WDBC	DIGITS	ABALON E	KIN8N M	Higgs	F-MNIST
Adam (без подбора)	0.079	0.122	0.154	0.433	0.108	0.541	0.439
Случайный поиск	0.105	0.112	0.161	0.429	0.118	0.567	0.291
TPE	0.132	0.121	0.202	0.427	0.103	0.567	0.314
GP-BO	0.165	0.185	0.160	0.425	0.104	0.562	0.310
Hyperband	0.223	0.117	0.161	0.428	0.113	0.544	0.315
BOHB	0.163	0.160	0.201	0.438	0.112	0.544	0.293
MFBO	0.160	0.121	0.223	0.494	0.226	0.564	0.319
Baseline DE	2.379	1.143	1.146	0.527	0.419	—	—
Optuna + DE	1.308	1.239	1.103	0.499	0.406	—	—
DE + DE Hybrid	1.268	1.075	1.924	0.488	0.545	—	—


Тестовая потеря (меньше — лучше).

- Эволюционные методы значимо уступают остальным на всех задачах.
- Между статистическими и байесовскими методами различия в качестве малы и неустойчивы по выбору задачи.
- MFBO на малых задачах уступает остальным байесовским из-за зашумлённости оценки при $s = 1$ эпоха.

Сходимость методов по времени работы

Метод	WINE	WDBC	DIGITS	ABALONE	KIN8NM	Higgs	F-MNIST
Adam (без подбора)	0.4	1.1	3.0	7.2	14.2	49.9	236
Случайный поиск	1.2	3.1	9.2	22.5	40.3	178	897
TPE	1.4	3.0	10.4	26.3	45	179	962
GP-BO	3.8	6.7	13.1	29.7	48.5	179	949
Hyperband	2.2	6.5	18.7	43.1	69.4	496	2731
BOHB	2.0	5.8	19.9	41.8	84.0	464	2404
MFBO	5.4	7.1	12.7	19.3	67.7	161	804
Baseline DE	19.5	33.2	—	—	—	—	—
Optuna + DE	442.7	84.2	—	—	—	—	—
DE + DE Hybrid	2107	16650	—	—	—	—	—

Стабильность результата по всем задачам



Условия применимости методов

По результатам проведённых экспериментов можно сформулировать следующие условия применимости рассмотренных методов:

- **На небольшой табличной задаче** достаточным будет Adam baseline или TPE
- **На объемной, вычислительно затратной задаче** оптимальным выбором будет MFBO или BONB
- **Если время работы метода** (при условии, что задача достаточно сложная) - приоритетная метрика задачи, то лучшим будет MFBO
- **Если CNN имеет нестабильный результат** (большой разброс тестовой потери), требуется использовать HPO
- **Если нет доступа к градиенту** оптимизируемого функционала, то возможно использование DE

Выводы и результаты работы

Выводы

1. На простых табличных задачах вычислительно затратный подбор гиперпараметров не оправдан.
2. Эволюционные методы значимо уступают статистическим и байесовским на всех рассмотренных задачах.
3. На больших задачах MFBO достигает качества Hyperband и BOHB примерно за 1/3 их времени и является оптимальным выбором при ограниченном вычислительном бюджете.
4. Для CNN на Fashion-MNIST подбор гиперпараметров снижает разброс потери и повышает устойчивость результата.
5. Выбор метода определяется сложностью задачи, допустимым временем обучения и требуемой стабильностью результата.

Результаты работы

1. Разработан единый воспроизводимый программный комплекс для запуска сравниваемых методов подбора гиперпараметров на рассматриваемых наборах данных.
2. Проведено систематическое сравнение методов по итоговому качеству, времени работы и стабильности результата, а также статистический анализ значимости их различий критериями Фридмана и Неменьи.
3. Сформулированы условия применимости методов.

Спасибо за внимание

Готов ответить на вопросы.

Многоуровневая задача оптимизации

Уровень точности $s \in [s_{\min}, s_{\max}]$ — число эпох обучения весов θ при оценке потери для гиперпараметров λ .

- $s = s_{\max}$ — точная, но дорогая оценка $\mathcal{L}_{\text{val}}(\lambda)$;
- малое s — дешёвая, но смещённая и зашумлённая оценка.

Задача оптимизации при ограниченном вычислительном бюджете B :

$$\lambda^* = \arg \min \mathcal{L}_{\text{val}}(\lambda, s_{\max}), \quad \text{при условии} \quad \sum c(s_i) \leq B,$$

где $c(s)$ — стоимость одной оценки на уровне точности s (растёт с увеличением s).

Алгоритм многоуровневой оптимизации должен распределять бюджет B между оценками разной точности так, чтобы максимально точно определить лучшее значение λ .

Статистический анализ различий

Critical Difference Diagram (loss_mean, N=5 datasets)




Диаграмма критической разности по пяти малым задачам

Результаты:

- Все методы имеют между собой различия
- Лучшие Adam и HPO методы значительно лучше худших DE методов
- Между методами Adam и HPO значимых различий нет, $p = 0.3$.

Критерий Фридмана:

$$F = 12N \cdot [\sum R_j^2 - k(k+1)^2 / 4] / [k(k+1)]$$

где N — число задач, k — число методов,
 R_j — средний ранг метода j .

Критическая разность (тест Немецки):

$$CD = q_\alpha \cdot \sqrt{ (k(k+1) / 6N) }$$

Два метода значимо различаются, если разность их средних рангов превышает CD .

Adam — Adaptive Moment Estimation

Идея

Градиентный метод обучения весов θ с адаптивным шагом. Хранит экспоненциальные скользящие средние градиента (1-й момент) и его квадрата (2-й момент); шаг по каждому параметру масштабируется индивидуально.

Обновление на шаге t

$$m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t \quad v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$$
$$\theta_t = \theta_{t-1} - \eta \cdot m_t / (\sqrt{v_t} + \varepsilon)$$

g_t — градиент потерь; m_t, v_t — оценки моментов с поправкой на смещение; $\beta_1=0.9, \beta_2=0.999, \varepsilon=10^{-8}$.

Роль в работе

- Обучает веса θ при фиксированных гиперпараметрах λ во всех методах класса A.
- Adam baseline — обучение без подбора λ ($h=256, lr=10^{-3}, dropout=0.2$); эталон сравнения.

Случайный поиск (Random Search)

Идея

Независимое случайное семплирование конфигураций из пространства Λ , без использования информации о ранее проверенных точках. Служит точкой отсчёта для всех более «умных» методов поиска.

Семплирование пространства гиперпараметров

- h (размер скрытого слоя) — равномерно из целочисленного диапазона $[128, 512]$.
- lr (скорость обучения) — логравномерно из $[10^{-4}, 5 \cdot 10^{-3}]$.
- `dropout` — равномерно из $[0.0, 0.5]$.

Как работает

Каждая конфигурация обучается на сокращённом числе эпох (`search_epochs`); лучшая по валидации доучивается на полном числе эпох (`final_epochs`).

TPE — Tree-structured Parzen Estimator

Идея

Байесовский метод. Моделирует не $p(y | \lambda)$, а $p(\lambda | y)$: наблюдения делятся на «хорошие» и «плохие» по порогу y^* (квантиль $\gamma = 0.25$), и для каждой группы строится своя плотность.

Две плотности и функция полезности

$$\begin{aligned} \ell(\lambda) &= p(\lambda | y < y^*) & g(\lambda) &= p(\lambda | y \geq y^*) \\ EI(\lambda) &\propto \ell(\lambda) / g(\lambda) \rightarrow \text{максимизируется} \end{aligned}$$

Как работает

- Плотности ℓ и g оцениваются ядерным сглаживанием (Parzen / KDE).
- Следующая λ выбирается там, где конфигурация вероятна как «хорошая» и маловероятна как «плохая».
- Реализация: библиотека Optuna.

GP-BO — байесовская оптимизация на гауссовском процессе

Идея

Классическая байесовская оптимизация. Суррогат — гауссовский процесс: по n наблюдениям $\{(\lambda_i, y_i)\}$ даёт нормальное апостериорное распределение целевой функции с $\mu(\lambda)$ и $\sigma^2(\lambda)$.

Функция полезности: q-Log Expected Improvement

$$q\text{LogEI}(\lambda) = \log E[\max(0, y^* - y(\lambda))]$$

y^* — лучшее найденное значение целевой функции среди собранных наблюдений.

Алгоритм

- Семплируются $n_i, i = 1, \dots, N$ = 4 случайные стартовые точки.
- Обучить GP → максимизировать qLogEI → оценить новую λ → добавить наблюдение.
- Повторять до исчерпания бюджета. Реализация: BoTorch.

Hyperband

Идея

Bandit-метод последовательного отсева (Successive Halving), без суррогатной модели. Много случайных конфигураций запускается на малом бюджете; худшие отсеиваются, лучшим бюджет увеличивается.

Схема Successive Halving

- Стартовый бюджет $r = 1$ эпоха; на каждой ступени остаётся $1/\eta$ лучших, их бюджет умножается на η .
- Максимальный бюджет $r = 20$ эпох (малые) / 12 эпох (большие); коэффициент редукции $\eta = 3$.

Особенности

- Многоуровневый: отсев по дешёвым промежуточным оценкам на малом числе эпох.
- Выбор конфигураций случайный — «ум» метода только в распределении бюджета.
- Реализация: HyperbandPruner + RandomSampler (Optuna).

BOHB — Bayesian Optimization HyperBand

Идея

Гибрид TPE и Hyperband. Сохраняет многоуровневое распределение бюджета от Hyperband, но конфигурации выбирает не случайно, а моделью TPE.

Состав

- Сэмплер — TPE: выбирает перспективные λ по отношению плотностей $\ell(\lambda) / g(\lambda)$.
- Pruner — Hyperband: отсеивает слабые конфигурации на малом бюджете.

Зачем

Устраняет главный недостаток Hyperband — случайный выбор конфигураций. Поиск направляется в перспективные области пространства, сохраняя выгоду раннего отсева.

- Реализация: TPE-сэмплер + Hyperband-pruner (Optuna).

MFBO — Multi-Fidelity Bayesian Optimization

Идея

Обобщение GP-BO на несколько уровней верности s . Суррогат — совместный гауссовский процесс по (λ, s) . Метод выбирает не только какую λ пробовать, но и на каком бюджете s .

Функция полезности: q-Multi-Fidelity Knowledge Gradient

$$\alpha(\lambda, s) = E[\max_{\lambda'} \mu_{+1}(\lambda', s_{ax}) - \max_{\lambda'} \mu(\lambda', s_{ax})] / c(s)$$

Числитель — ожидаемое улучшение лучшего предсказания на макс. верности после оценки (λ, s) ; $c(s)$ — её стоимость.

Как работает

- Дешёвые оценки при малом s быстро отсеивают неперспективные области.
- Дорогие оценки при s_{ax} уточняют лучших кандидатов.
- Уровни верности: $\{1, 5, 20\}$ эпох (малые) / $\{1, 4, 12\}$ (большие). Реализация: SingleTaskMultiFidelityGP, BoTorch.

DE — дифференциальная эволюция (Differential Evolution)

Идея

Эволюционный метод оптимизации в постановке black-box (без градиента). Оптимизирует напрямую веса MLP. Используется схема DE/best/1/bin.

Мутация, кроссовер и селекция

$$v_i = x_{best} + F \cdot (x_{r_1} - x_{r_2}) \quad (\text{мутация})$$

$$x_i' = u_i, \text{ если } f(u_i) < f(x_i); \text{ иначе } x_i \quad (\text{селекция})$$

u_i — пробный вектор после биномиального кроссовера с вероятностью Cr; r_1, r_2 — случайные особи. Параметры: N_pop = 40, N_gen = 60, F = 0.6, Cr = 0.9.

Варианты в работе

- Baseline DE — эволюция весов; Optuna+DE — TPE подбирает h, DE учит веса.
- DE+DE Hybrid — внешний DE по (h, F, Cr), внутренний — веса. Только для MLP на табличных данных.