

Московский государственный университет имени М. В. Ломоносова



Факультет Вычислительной Математики и Кибернетики  
Кафедра Математических Методов Прогнозирования

Мищук Глеб Александрович

**«Оптимизация параметров глубокой сети с использованием  
байесовского подхода»**

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**

Научный руководитель:  
Кравцова О. А.

Москва, 2026

# Содержание

|          |                                                                           |           |
|----------|---------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Введение</b>                                                           | <b>3</b>  |
| <b>2</b> | <b>Структура работы</b>                                                   | <b>5</b>  |
| <b>3</b> | <b>Постановка задачи</b>                                                  | <b>6</b>  |
| 3.1      | Обучение нейронной сети . . . . .                                         | 6         |
| 3.2      | Оптимизация гиперпараметров . . . . .                                     | 6         |
| 3.3      | Многоуровневая постановка . . . . .                                       | 6         |
| 3.4      | Метрики качества . . . . .                                                | 7         |
| 3.5      | Постановка black-box для эволюционных методов . . . . .                   | 7         |
| <b>4</b> | <b>Обзор методов</b>                                                      | <b>8</b>  |
| 4.1      | Adam baseline . . . . .                                                   | 8         |
| 4.2      | Случайный поиск . . . . .                                                 | 8         |
| 4.3      | TPE — Tree-structured Parzen Estimator . . . . .                          | 9         |
| 4.4      | GP-BO — байесовская оптимизация на основе гауссовского процесса . . . . . | 9         |
| 4.5      | Hyperband . . . . .                                                       | 10        |
| 4.6      | BOHB — Bayesian Optimization Hyperband . . . . .                          | 10        |
| 4.7      | MFBO — многоуровневая байесовская оптимизация . . . . .                   | 10        |
| 4.8      | Эволюционные методы (Класс B) . . . . .                                   | 11        |
| <b>5</b> | <b>Эксперименты</b>                                                       | <b>12</b> |
| 5.1      | Используемые наборы данных . . . . .                                      | 12        |
| 5.2      | Архитектуры моделей и пространство гиперпараметров . . . . .              | 13        |
| 5.3      | Результаты на малых табличных наборах данных . . . . .                    | 14        |
| 5.3.1    | Анализ результатов на малых наборах данных . . . . .                      | 15        |
| 5.4      | Результаты на больших задачах: Higgs и Fashion-MNIST . . . . .            | 17        |
| 5.4.1    | Анализ результатов на больших наборах данных . . . . .                    | 17        |
| 5.5      | Анализ кривых сходимости . . . . .                                        | 18        |
| 5.5.1    | Сходимость по времени работы . . . . .                                    | 18        |
| 5.5.2    | Сходимость по числу оценок при максимальной верности . . . . .            | 19        |
| 5.5.3    | Сходимость по эпохам-эквивалентам . . . . .                               | 19        |
| 5.5.4    | Сравнение DE и НРО на относительной шкале прогресса . . . . .             | 20        |
| 5.6      | Статистический анализ . . . . .                                           | 21        |
| 5.7      | Ограничения работы . . . . .                                              | 22        |
| <b>6</b> | <b>Выводы</b>                                                             | <b>24</b> |
| <b>7</b> | <b>Заключение</b>                                                         | <b>25</b> |

## Аннотация

Подбор гиперпараметров (НРО) является одним из ключевых этапов построения качественной модели машинного обучения, и стоимость его проведения зачастую сопоставима со стоимостью самого обучения. Классические методы, такие как поиск по сетке и случайный поиск, не используют информацию о ранее проверенных конфигурациях, что приводит к избыточному расходу вычислительного бюджета. Байесовская оптимизация и её многоуровневые обобщения позволяют направлять поиск в перспективные области пространства гиперпараметров, моделируя зависимость целевой функции от значений гиперпараметров и используя дешёвые приближённые оценки для отсева неперспективных конфигураций. В настоящей работе проводится систематическое сравнение байесовских методов оптимизации гиперпараметров глубоких сетей с альтернативными подходами на семи наборах данных различной размерности и сложности. Реализован унифицированный экспериментальный программный комплекс с поддержкой 10 методов оптимизации, выполнен корректный статистический анализ различий между методами с использованием критерия Фридмана и пост-хок теста Немени. Показано, что НРО не является универсально полезным методом: на простых задачах с плоским ландшафтом функции потерь алгоритм Adam без подбора гиперпараметров сопоставим с методами, его использующими, тогда как на более чувствительных задачах подбор гиперпараметров повышает стабильность результата. Основное преимущество многоуровневой байесовской оптимизации (MFBO) состоит не в максимальном качестве, а в сокращении времени получения сопоставимого результата.

# 1 Введение

В данной работе под оптимизацией параметров понимается оптимизация гиперпараметров модели и процедуры обучения, веса сети обучаются стандартным градиентным методом Adam [13].

Современные глубокие нейронные сети характеризуются большим числом гиперпараметров, значения которых существенно влияют на качество финальной модели. К таким гиперпараметрам относятся, в частности, размер скрытых слоёв, темп обучения, коэффициент регуляризации, число эпох обучения, размер мини-выборки и другие. В отличие от обучаемых параметров (весов), гиперпараметры не подвергаются градиентной оптимизации в рамках обычного процесса обучения и должны быть подобраны отдельно.

Полный перебор по сетке гиперпараметров (grid search) практически невозможен из-за экспоненциального роста числа конфигураций при увеличении размерности пространства поиска. Случайный поиск (random search), являясь более гибкой альтернативой, не использует информацию о ранее проверенных точках и расходует бюджет неэффективно [3]. В связи с этим большее распространение получают методы, явно моделирующие зависимость метрики качества от значений гиперпараметров и направляющие поиск в перспективные области пространства.

Среди таких методов центральное место занимает **байесовская оптимизация** (Bayesian Optimization, BO) [1], в основе которой лежит построение суррогатной вероятностной модели целевой функции (как правило, гауссовского процесса) и оптимизация функции полезности (acquisition function) для выбора следующей точки. Классическая байесовская оптимизация с гауссовскими процессами требует, тем не менее, дорогостоящей оценки целевой функции — то есть полного обучения модели — на каждой итерации, что становится узким местом при работе с большими сетями и большими наборами данных.

Эту проблему решают **многоуровневые** (multi-fidelity) методы, которые используют дешёвые приближённые оценки целевой функции (например, обучение модели в течение небольшого числа эпох или на подвыборке данных) для предварительного отсева неперспективных конфигураций, оставляя дорогие полные обучения только для отобранных. К этому семейству относятся FABOLAS [7], Hyperband [4], BOHB [5] и многоуровневая байесовская оптимизация (Multi-Fidelity Bayesian Optimization, MFBO) [6].

В дипломной работе основное внимание уделено байесовскому подходу, оптимизирующему гиперпараметры при фиксированном способе обучения весов градиентным методом, причём эволюционные подходы сохранены как дополнительный референс в отдельном подразделе.

**Цель работы** — провести систематическое сравнение классических и многоуров-

невых байесовских методов оптимизации гиперпараметров глубоких сетей с альтернативными подходами, определить условия, при которых каждый метод даёт преимущество, и количественно оценить эффективность многоуровневых подходов на задачах разной вычислительной стоимости.

**Задачи работы:**

1. Формализовать постановку задачи оптимизации гиперпараметров и выбрать метрики качества и бюджета.
2. Реализовать единый воспроизводимый программный комплекс с поддержкой нескольких наборов данных разной размерности.
3. Реализовать и сравнить методы оптимизации гиперпараметров: Adam (без подбора), случайный поиск, TPE, GP-BO, Hyperband, BOHB и MFBO.
4. Дополнительно реализовать эволюционные подходы (Baseline DE, Optuna+DE, DE+DE Hybrid) как black-box оптимизаторы.
5. Провести статистический анализ различий между методами с использованием критерия Фридмана и пост-хок теста Немени.
6. Сформулировать рекомендации по выбору метода оптимизации в зависимости от характеристик задачи.

## 2 Структура работы

Работа организована следующим образом:

- **Постановка задачи** (раздел 3) формализует задачи обучения весов и подбора гиперпараметров, вводит метрики качества и понятие многоуровневого бюджета.
- **Обзор методов** (раздел 4) детализирует все десять рассматриваемых методов, разбитых на два класса:
  - Класс А — оптимизация гиперпараметров при фиксированном Adam-обучении весов;
  - Класс В — эволюционная оптимизация в постановке black-box.
- **Эксперименты** (раздел 5) включают:
  - Описание используемых наборов данных (раздел 5.1);
  - Описание архитектур моделей и протокола экспериментов (раздел 5.2);
  - Сравнение методов на малых табличных задачах (раздел 5.3);
  - Сравнение методов на больших задачах — Higgs и Fashion-MNIST (раздел 5.4);
  - Анализ кривых сходимости (раздел 5.5);
  - Статистический анализ различий между методами (раздел 5.6).
- **Выводы** (раздел 6) суммируют ключевые наблюдения и формулируют рекомендации по выбору метода.
- **Заключение** (раздел 7) обсуждает научную и практическую значимость полученных результатов и направления продолжения исследования.

## 3 Постановка задачи

### 3.1 Обучение нейронной сети

Пусть  $f(\cdot; \theta, \lambda)$  — нейронная сеть, параметризованная **весами**  $\theta \in \mathbb{R}^D$  и **гиперпараметрами**  $\lambda \in \Lambda$ , где  $\Lambda$  — допустимое пространство гиперпараметров. Обучение весов при фиксированных  $\lambda$  заключается в решении задачи минимизации эмпирического риска на обучающей выборке  $\mathcal{D}_{\text{tr}}$ :

$$\theta^*(\lambda) = \arg \min_{\theta} \frac{1}{|\mathcal{D}_{\text{tr}}|} \sum_{(x,y) \in \mathcal{D}_{\text{tr}}} L(f(x; \theta, \lambda), y), \quad (1)$$

где  $L$  — функция потерь, специфичная для задачи (кросс-энтропия для классификации, среднеквадратичная ошибка для регрессии).

### 3.2 Оптимизация гиперпараметров

Качество весов, найденных при фиксированных гиперпараметрах  $\lambda$ , оценивается на отдельной валидационной выборке  $\mathcal{D}_{\text{val}}$ . Задача подбора гиперпараметров формулируется как:

$$\lambda^* = \arg \min_{\lambda \in \Lambda} \mathcal{L}_{\text{val}}(\lambda) \equiv \frac{1}{|\mathcal{D}_{\text{val}}|} \sum_{(x,y) \in \mathcal{D}_{\text{val}}} L(f(x; \theta^*(\lambda), \lambda), y). \quad (2)$$

Особенность этой задачи состоит в следующем: целевая функция  $\mathcal{L}_{\text{val}}(\lambda)$  не имеет аналитической формы, её градиент по  $\lambda$  напрямую недоступен, и каждая её оценка требует полного обучения весов. Это делает задачу (2) дорогой задачей оптимизации в постановке black-box.

### 3.3 Многоуровневая постановка

Многоуровневые методы вводят дополнительный параметр  $s \in [s_{\min}, s_{\max}]$  — уровень верности (fidelity), который контролирует точность оценки целевой функции. Обозначим  $\mathcal{L}_{\text{val}}(\lambda, s)$  значение целевой функции при бюджете  $s$  (например,  $s$  — число эпох обучения весов). При  $s = s_{\max}$  оценка близка к истинному  $\mathcal{L}_{\text{val}}(\lambda)$ , при меньших  $s$  оценка дешевле, но смещена и зашумлена.

Задача оптимизации гиперпараметров при ограниченном вычислительном бюджете  $B$  принимает вид:

$$\lambda^* = \arg \min_{\lambda} \mathcal{L}_{\text{val}}(\lambda, s_{\max}), \quad \text{при условии} \quad \sum_i c(s_i) \leq B, \quad (3)$$

где  $c(s)$  — стоимость одной оценки на уровне верности  $s$ , а суммирование ведётся по всем оценкам, выполненным методом в ходе работы.

### 3.4 Метрики качества

Для согласованного сравнения всех методов используются единые метрики качества, специфичные для типа задачи.

**Классификация.** Используется кросс-энтропия с усреднением по объектам:

$$L_{\text{CE}}(\hat{y}, y) = - \sum_{c=1}^C y_c \log \hat{y}_c, \quad \mathcal{L}_{\text{CE}} = \frac{1}{N} \sum_{i=1}^N L_{\text{CE}}(\hat{y}_i, y_i), \quad (4)$$

где  $C$  — число классов,  $\hat{y}_c$  — предсказанная вероятность  $c$ -го класса,  $y_c$  — one-hot представление истинной метки. В качестве вторичной (интерпретируемой) метрики приводится точность (ассигасу) — доля верно классифицированных объектов.

**Регрессия.** Используется среднеквадратичная ошибка на нормализованной целевой переменной:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2. \quad (5)$$

Дополнительно вычисляется коэффициент детерминации  $R^2$  на исходном (ненормализованном) масштабе для интерпретируемости.

### 3.5 Постановка black-box для эволюционных методов

В отличие от градиентных методов обучения весов, эволюционные методы (DE) в данной работе рассматриваются как **black-box оптимизаторы**: целевая функция (fitness-функция) вычисляется на валидационной выборке. Это методологическое допущение, отвечающее индустриальной практике, в которой градиент модели может быть недоступен (например, при работе с обёрткой над внешним сервисом). Следует отметить, что использование валидационной выборки в качестве целевой функции потенциально приводит к смещению, поскольку валидация одновременно играет роль критерия отбора и оценки качества; данное смещение принимается как часть постановки в выбранной парадигме.

DE-методы вынесены в отдельный подраздел и не претендуют на роль основного инструмента в данной работе. Они используются как референсная точка, демонстрирующая поведение принципиально иного класса методов на тех же задачах.



## 4 Обзор методов

В работе сравниваются десять методов, разбитых на два класса.

**Класс А. Оптимизация гиперпараметров** при фиксированном способе обучения весов (Adam):

1. Adam baseline (без подбора);
2. Случайный поиск (Random Search);
3. TPE (Tree-structured Parzen Estimator);
4. GP-BO (байесовская оптимизация на основе гауссовского процесса);
5. Hyperband;
6. BOHB (Bayesian Optimization Hyperband);
7. MFBO (многоуровневая байесовская оптимизация).

**Класс В. Эволюционная оптимизация** (black-box):

8. Baseline DE (DE по весам MLP);
9. Optuna+DE (TPE подбирает  $h$ , DE учит веса);
10. DE+DE Hybrid (внешний DE по гиперпараметрам, внутренний по весам).

### 4.1 Adam baseline

Чистое обучение многослойного перцептрона (MLP) или свёрточной сети (CNN) с фиксированными значениями гиперпараметров: размер скрытого слоя  $h = 256$ , скорость обучения  $lr = 10^{-3}$ ,  $dropout = 0.2$ . Метод служит абсолютным референсом, против которого сравниваются все остальные подходы. На малых наборах данных используется обучение в течение 50 эпох, на больших — 20 эпох (см. раздел [5.2](#)).

### 4.2 Случайный поиск

Случайное семплирование конфигураций гиперпараметров из заданного пространства:  $h$  выбирается равномерно из целочисленного диапазона,  $lr$  — логравномерно,  $dropout$  — равномерно из вещественного диапазона. Каждая конфигурация обучается на сокращённом числе эпох (`search_epochs`); по результату выбирается лучшая, доучиваемая на полном числе эпох (`final_epochs`). Случайный поиск служит точкой отсчёта для всех более сложных методов поиска гиперпараметров [3].

### 4.3 TPE — Tree-structured Parzen Estimator

TPE [2] моделирует распределение гиперпараметров условно лучшим и худшим наблюдениям. Пусть  $y^*$  — порог разделения наблюдений на «хорошие» и «плохие» (как правило, квантиль уровня  $\gamma = 0.25$  от собранных  $y$ ). Тогда строятся две плотности:

$$\ell(\lambda) = p(\lambda \mid y < y^*), \quad g(\lambda) = p(\lambda \mid y \geq y^*). \quad (6)$$

Функция полезности (acquisition function) определяется отношением плотностей:

$$\text{EI}(\lambda) \propto \frac{\ell(\lambda)}{g(\lambda)}, \quad (7)$$

и максимизируется при выборе следующей точки. В работе используется реализация из библиотеки Optuna [10].

### 4.4 GP-BO — байесовская оптимизация на основе гауссовского процесса

Классический подход [1]. Суррогатная модель — гауссовский процесс; для  $n$  собранных наблюдений  $\{(\lambda_i, y_i)\}_{i=1}^n$  постериорное распределение целевой функции в новой точке  $\lambda$  имеет вид нормального с параметрами  $\mu_n(\lambda)$  и  $\sigma_n^2(\lambda)$ .

В качестве функции полезности используется численно устойчивая версия Expected Improvement — q-Log Expected Improvement (qLogEI):

$$\text{qLogEI}(\lambda) = \log \mathbb{E}[\max(0, y^* - y(\lambda))], \quad (8)$$

где  $y^*$  — наилучшее значение целевой функции среди собранных. Алгоритм состоит из следующих шагов:

1. Семплируется  $n_{\text{init}} = 4$  начальных точки случайно.
2. На собранных  $(\lambda, y)$  обучается гауссовский процесс.
3. Максимизируется функция полезности (8); выбранная точка  $\lambda_{n+1}$  оценивается, наблюдение добавляется к собранным.
4. Шаги 2–3 повторяются до исчерпания бюджета.

В качестве реализации используется библиотека BoTorch [11].

## 4.5 Hyperband

Bandit-метод последовательного отсева [4]: запускается большое число конфигураций на малом бюджете, отсеиваются худшие, оставшимся бюджет удваивается, процесс повторяется. Метод не использует байесовский подход; выбор конфигураций случайный, отсеивание определяется текущим состоянием испытаний. В реализации используется HyperbandPruner совместно с RandomSampler из Optuna.

Параметры метода:

- $r_{\min} = 1$  — минимальный бюджет на одно испытание (1 эпоха);
- $r_{\max}$  — максимальный бюджет (20 эпох на малых, 12 на больших);
- $\eta = 3$  — коэффициент редукции (на каждом этапе оставляется  $1/\eta$  конфигураций).

## 4.6 BOHB — Bayesian Optimization Hyperband

Гибрид TPE и Hyperband [5]: семплер выбирает перспективные конфигурации (вместо случайного семплирования), прунер отсеивает плохие на малом бюджете. Реализация: TPE-семплер с pruner Hyperband в Optuna.

## 4.7 MFBO — многоуровневая байесовская оптимизация

Обобщение GP-BO на несколько уровней верности [6]. Суррогатная модель — SingleTaskMultiFidelityGP из BoTorch, моделирующий совместное распределение по  $(\lambda, s)$ , где  $s$  — уровень верности (число эпох обучения).

В качестве функции полезности используется q-Multi-Fidelity Knowledge Gradient с учётом стоимости [6]:

$$\alpha_{\text{KG}}(\lambda, s) = \frac{\mathbb{E}[\max_{\lambda'} \mu_{n+1}(\lambda', s_{\max}) - \max_{\lambda'} \mu_n(\lambda', s_{\max})]}{c(s)}, \quad (9)$$

где числитель — ожидаемое улучшение наилучшего предсказания на максимальной верности после получения наблюдения  $(\lambda, s)$ , а знаменатель — стоимость этого наблюдения. Метод выбирает не только *какую конфигурацию* пробовать, но и *на каком бюджете*: дешёвые оценки на низкой  $s$  позволяют быстро отсеять неперспективные регионы, дорогие оценки на  $s_{\max}$  — уточнить лучших кандидатов.

В работе использовались уровни верности  $\{1, 5, 20\}$  эпох на малых наборах данных и  $\{1, 4, 12\}$  на больших.

## 4.8 Эволюционные методы (Класс В)

В постановке black-box (раздел 3.5) целевая функция вычисляется на валидационной выборке.

**Baseline DE.** Дифференциальная эволюция (DE/best/1/bin) [9] оптимизирует напрямую веса MLP с фиксированной архитектурой ( $h = 256$ ). Размер популяции  $N_{\text{pop}} = 40$ , число поколений  $N_{\text{gen}} = 60$ , параметры мутации  $F = 0.6$ , кроссовера  $\text{Cr} = 0.9$ .

На каждой итерации DE для каждой особи  $i$  из популяции выбираются две случайные особи  $r_1, r_2$  (отличные от  $i$ ) и формируется мутант:

$$v_i = x_{\text{best}} + F \cdot (x_{r_1} - x_{r_2}), \quad (10)$$

где  $x_{\text{best}}$  — лучшая на данный момент особь. Мутант скрещивается с текущей особью по биномиальной схеме с вероятностью  $\text{Cr}$ , и пробный вектор  $u_i$  замещает  $x_i$  только если значение целевой функции улучшается:

$$x_i^{\text{new}} = \begin{cases} u_i, & \text{если } f(u_i) < f(x_i), \\ x_i, & \text{иначе.} \end{cases} \quad (11)$$

**Optuna+DE.** Внешний цикл TPE подбирает размер скрытого слоя  $h$ , для каждого  $h$  запускается внутренний DE для весов модели с этим  $h$ .

**DE+DE Hybrid.** Внешняя эволюция оптимизирует тройку  $(h, F, \text{Cr})$  путём обычного DE, внутренняя — веса модели; для оценки внешней особи запускается полный внутренний DE, его лучшее значение целевой функции используется как значение целевой функции для внешней особи.

DE-методы применимы только к MLP на табличных данных. На свёрточных сетях с миллионами параметров они нецелесообразны по соображениям масштабируемости и не запускались.

## 5 Эксперименты

### 5.1 Используемые наборы данных

Для оценки методов выбран набор из семи открытых наборов данных разной размерности и сложности (таблица 1).

Таблица 1: Используемые наборы данных

| # | Название      | Тип задачи        | $N$    | Признаков      | Источник    |
|---|---------------|-------------------|--------|----------------|-------------|
| 1 | WINE          | классиф. (3 кл.)  | 178    | 13             | sklearn     |
| 2 | WDBC          | классиф. (2 кл.)  | 569    | 30             | UCI         |
| 3 | DIGITS        | классиф. (10 кл.) | 1 797  | 64             | sklearn     |
| 4 | ABALONE       | регрессия         | 4 177  | 8 (1 кат.)     | UCI         |
| 5 | KIN8NM        | регрессия         | 8 192  | 8              | OpenML      |
| 6 | Higgs         | классиф. (2 кл.)  | 98 050 | 28             | OpenML      |
| 7 | Fashion-MNIST | классиф. (10 кл.) | 60 000 | $28 \times 28$ | torchvision |

Малые и средние наборы данных (1–5) обеспечивают быструю проверку методов и позволяют запускать многочисленные значения генератора случайных чисел; большие — Higgs и Fashion-MNIST — нужны для демонстрации преимуществ многоуровневых подходов, для которых полное обучение оказывается достаточно дорогим, чтобы экономия на низкой верности имела практический смысл.

**Предобработка.** Для табличных наборов данных разбиение на обучающую, валидационную и тестовую части проводится со стратификацией для классификации в соотношении 70/15/15 с фиксацией начального состояния генератора случайных чисел. Категориальные признаки кодируются методом one-hot encoding, числовые — стандартизированы (StandardScaler с подгонкой на обучающей части). Для регрессии целевая переменная нормализуется (среднее и стандартное отклонение оцениваются по обучающей части);  $R^2$  затем вычисляется на исходном масштабе. Пропущенные значения числовых признаков замещаются медианой обучающей части (SimpleImputer), категориальные — строкой "missing"; дополнительно применяется `np.nan_to_num` для защиты от численных артефактов на больших наборах данных (Higgs).

Для Fashion-MNIST применяется поканальная стандартизация, разбиение на обучение и валидацию 85/15 от стандартной обучающей выборки, отдельная тестовая выборка.

Fashion-MNIST [14] рассматривается в работе отдельно как задача другой модальности и другой архитектуры. Основной статистический тест для класса A проводится на табличных задачах, где архитектура и протокол испытания сопоставимы. Набор данных Higgs [15] представляет собой масштабную табличную задачу, требующую сравнимо больше вычислительных ресурсов, нежели малые наборы данных.

## 5.2 Архитектуры моделей и пространство гиперпараметров

**MLP** (для табличных данных): четыре линейных слоя  $\text{in} \rightarrow h \rightarrow h/2 \rightarrow h/4 \rightarrow \text{out}$  с активацией ReLU и слоем Dropout между слоями, инициализация Кайминга.

**CNN** (для Fashion-MNIST): три свёрточных блока ( $\text{Conv}3 \times 3$  — BatchNorm — ReLU — MaxPool) с числом каналов  $h, 2h, 4h$ , глобальный AdaptiveAvgPooling, линейный классификатор. Параметр  $h$  задаёт ширину сети и входит в пространство гиперпараметров.

**Пространство гиперпараметров** едино для всех методов класса A:

- $h \in [128, 512]$  — целочисленный диапазон;
- $\text{lr} \in [10^{-4}, 5 \cdot 10^{-3}]$  — логравномерное распределение;
- $\text{dropout} \in [0, 0.5]$  — равномерное распределение.

**Логирование вычислительного бюджета.** Для каждого метода в течение прогона логируется траектория сходимости в виде последовательности точек, содержащих следующую информацию:

- время от старта (wall-clock);
- число оценок при максимальной верности ( $n_{\text{full}}$ );
- число оценок при пониженной верности ( $n_{\text{partial}}$ );
- эпохи-эквиваленты ( $n_{\text{ep}}$ ) — суммарное число пройденных по данным эпох;
- значение минимизируемой методом величины (train fitness);
- значение валидационной потери (val loss) — объективная метрика для сравнения;
- накопленный минимум валидационной потери (best-so-far val loss).

Это позволяет строить кривые сходимости с разными осями абсцисс и сравнивать методы при сопоставимом бюджете.

Важно отметить специфику сравнения бюджетов. Adam baseline не тратит вычислительные ресурсы на поиск, поэтому весь ресурс уходит на одно полное обучение (20 эпох). Методы НРО часть ресурсов тратят на оценку различных конфигураций, поэтому сравнение отражает сценарий «поиск + финальное обучение» (например, 15 эпох финального обучения), а не прямое сравнение финальных моделей при одинаковом числе эпох.

**Воспроизводимость.** Все эксперименты повторяются на 5 случайных начальных состояниях генератора случайных чисел:  $\{42, 123, 2024, 7, 999\}$ . Зафиксированы `random_state` в `numpy/sklearn`, `torch.manual_seed` и `cudnn.deterministic` в PyTorch.

**Аппаратное обеспечение.** Эксперименты на малых наборах данных проводились на NVIDIA RTX 4060 Laptop (8 GB), эксперименты на Higgs и Fashion-MNIST — на NVIDIA A100 (80 GB) через Google Colab.

### 5.3 Результаты на малых табличных наборах данных

В этом разделе приводятся результаты сравнения всех десяти методов на пяти малых табличных наборах данных (WINE, WDBC, DIGITS, ABALONE, KIN8NM). Сводка тестовых потерь (mean  $\pm$  std по 5 значениям начального состояния) представлена в таблице 2, точность/ $R^2$  — в таблице 3.

Таблица 2: Тестовая потеря (mean  $\pm$  std по 5 значениям начального состояния) на малых наборах данных. Полужирным выделены лучшие результаты в столбце

| Метод           | WINE                     | WDBC                     | DIGITS                   | ABALONE                  | KIN8NM                   |
|-----------------|--------------------------|--------------------------|--------------------------|--------------------------|--------------------------|
| Adam baseline   | <b>0.079</b> $\pm$ 0.080 | 0.122 $\pm$ 0.146        | <b>0.154</b> $\pm$ 0.074 | 0.433 $\pm$ 0.039        | 0.108 $\pm$ 0.006        |
| Случайный поиск | 0.105 $\pm$ 0.163        | <b>0.112</b> $\pm$ 0.086 | 0.161 $\pm$ 0.105        | 0.429 $\pm$ 0.036        | 0.118 $\pm$ 0.011        |
| Adam+TPE        | 0.132 $\pm$ 0.088        | 0.121 $\pm$ 0.133        | 0.202 $\pm$ 0.122        | 0.427 $\pm$ 0.043        | <b>0.103</b> $\pm$ 0.011 |
| Adam GP-BO      | 0.165 $\pm$ 0.185        | 0.185 $\pm$ 0.116        | 0.160 $\pm$ 0.112        | <b>0.425</b> $\pm$ 0.035 | 0.104 $\pm$ 0.003        |
| Adam Hyperband  | 0.223 $\pm$ 0.212        | <b>0.117</b> $\pm$ 0.107 | 0.161 $\pm$ 0.104        | 0.428 $\pm$ 0.051        | 0.113 $\pm$ 0.010        |
| Adam BOHB       | 0.163 $\pm$ 0.257        | 0.160 $\pm$ 0.111        | 0.201 $\pm$ 0.130        | 0.438 $\pm$ 0.056        | 0.112 $\pm$ 0.017        |
| Adam MFBO       | 0.160 $\pm$ 0.110        | 0.121 $\pm$ 0.058        | 0.223 $\pm$ 0.104        | 0.494 $\pm$ 0.084        | 0.226 $\pm$ 0.084        |
| Baseline DE     | 2.379 $\pm$ 2.276        | 1.143 $\pm$ 0.522        | 1.146 $\pm$ 0.171        | 0.527 $\pm$ 0.048        | 0.419 $\pm$ 0.042        |
| Optuna+DE       | 1.308 $\pm$ 1.391        | 1.239 $\pm$ 0.673        | 1.103 $\pm$ 0.143        | 0.499 $\pm$ 0.031        | 0.406 $\pm$ 0.042        |
| DE+DE Hybrid    | 1.268 $\pm$ 1.149        | 1.075 $\pm$ 0.918        | 1.924 $\pm$ 0.220        | 0.488 $\pm$ 0.052        | 0.545 $\pm$ 0.019        |

Таблица 3: Тестовая точность (для классификации) и  $R^2$  (для регрессии) на малых наборах данных. Полужирным выделены лучшие результаты в столбце

| Метод           | Точность $\uparrow$ |              |              | $R^2$ $\uparrow$ |              |
|-----------------|---------------------|--------------|--------------|------------------|--------------|
|                 | WINE                | WDBC         | DIGITS       | ABALONE          | KIN8NM       |
| Adam baseline   | 0.970               | <b>0.974</b> | <b>0.981</b> | 0.560            | 0.891        |
| Случайный поиск | <b>0.985</b>        | 0.970        | 0.977        | 0.564            | 0.882        |
| Adam+TPE        | 0.963               | 0.970        | 0.976        | 0.565            | <b>0.897</b> |
| Adam GP-BO      | 0.963               | 0.963        | 0.976        | <b>0.567</b>     | 0.895        |
| Adam Hyperband  | 0.963               | 0.972        | 0.976        | 0.566            | 0.886        |
| Adam BOHB       | 0.970               | 0.965        | 0.974        | 0.557            | 0.887        |
| Adam MFBO       | 0.963               | 0.965        | 0.962        | 0.500            | 0.771        |
| Baseline DE     | 0.882               | 0.935        | 0.714        | 0.462            | 0.580        |
| Optuna+DE       | 0.904               | 0.933        | 0.707        | 0.489            | 0.592        |
| DE+DE Hybrid    | 0.815               | 0.919        | 0.402        | 0.505            | 0.453        |

Визуальное представление тестовой потери всех методов на всех наборах данных приведено на рисунке 1. Столбчатая диаграмма наглядно демонстрирует две качественно различные группы: семь методов класса А (тёмно-синие и сине-зелёные

оттенки) образуют близкую группу с сопоставимыми значениями потерь, тогда как три метода класса В (оранжево-жёлтые оттенки) на каждом наборе данных значительно отклоняются вверх. Особенно заметен этот разрыв на DIGITS, где методы класса В дают потерю порядка 1.0–2.0 при потере методов класса А в пределах 0.15–0.25.




Рис. 1: Тестовая потеря на малых табличных наборах данных. Методы класса А дают близкие значения потерь, методы DE заметно уступают на DIGITS и регрессионных задачах.

### 5.3.1 Анализ результатов на малых наборах данных

Из таблиц 2, 3 и рисунка 1 можно сделать несколько ключевых наблюдений.

Во-первых, **все методы класса А демонстрируют сопоставимые результаты** на каждом из пяти малых наборов данных. Разница между лучшим и худшим методом класса А (включая Adam baseline) по тестовой потере не превышает 30% относительной величины, причём почти всегда укладывается в одно стандартное отклонение по значениям начального состояния. На WINE Adam baseline даёт лучший результат (0.079); на WDBC — случайный поиск (0.112); на DIGITS — снова Adam baseline (0.154); на ABALONE — GP-BO (0.425); на KIN8NM — TPE (0.103). Стабильного победителя среди методов класса А нет.

Во-вторых, в рамках выбранного размера вычислительных ресурсов DE-методы существенно уступают НРО-подходам с Adam по средним значениям качества и рангам. Особенно сильный разрыв наблюдается на DIGITS и регрессионных задачах. При этом статистический тест подтверждает наличие различий между методами в целом, а пост-хок анализ (подробнее в разделе 5.6) — значимость различий между лучшими методами класса А и худшими методами класса В.

В-третьих, **Adam MFBO на малых наборах данных работает хуже остальных методов класса А**. На ABALONE он даёт  $R^2 = 0.500$  против 0.557–0.567 у конкурентов, на KIN8NM —  $R^2 = 0.771$  против 0.882–0.897. Это ожидаемое поведение MFBO в режиме малой верности: оценка  $\mathcal{L}_{\text{val}}(\lambda, s)$  при  $s = 1$  эпохе на маленькой выборке (4–8 тысяч объектов) сильно зашумлена, и многоуровневый гауссовский



процесс плохо предсказывает оценку при максимальной верности по оценке при низкой верности. Метод не обладает достаточным числом наблюдений для уточнения корреляции между уровнями верности.

В-четвёртых, **время работы методов** (таблица 4) ожидаемо растёт с переходом от Adam baseline к более сложным методам. Однако даже Hyperband и BOHB — наиболее «дорогие» методы класса А — укладываются в 50–100 секунд на одно прохождение для KIN8NM, что меньше, чем у DE-методов (100–16000 секунд для DE+DE Hybrid). Огромная дисперсия времени DE+DE Hybrid связана с вложенной эволюцией: внутренний DE может неожиданно долго не сходиться при некоторых значениях  $(F, Cr)$ , выдаваемых внешним поиском.

Таблица 4: Время работы (mean  $\pm$  std по 5 значениям начального состояния, секунды) на малых наборах данных

| Метод           | WINE              | WDBC              | DIGITS         | ABALONE         | KIN8NM          |
|-----------------|-------------------|-------------------|----------------|-----------------|-----------------|
| Adam baseline   | 0.4 $\pm$ 0.1     | 1.1 $\pm$ 0.3     | 3.0 $\pm$ 0.4  | 7.2 $\pm$ 0.8   | 14.2 $\pm$ 2.0  |
| Случайный поиск | 1.2 $\pm$ 0.4     | 3.1 $\pm$ 0.7     | 9.2 $\pm$ 0.6  | 22.5 $\pm$ 3.4  | 40.3 $\pm$ 4.3  |
| Adam+TPE        | 1.4 $\pm$ 0.8     | 3.0 $\pm$ 0.6     | 10.4 $\pm$ 1.7 | 26.3 $\pm$ 4.5  | —               |
| Adam GP-BO      | 3.8 $\pm$ 0.6     | 6.7 $\pm$ 0.7     | 13.1 $\pm$ 0.9 | 29.7 $\pm$ 6.1  | 48.5 $\pm$ 10.7 |
| Adam Hyperband  | 2.2 $\pm$ 0.3     | 6.5 $\pm$ 1.9     | 18.7 $\pm$ 3.2 | 43.1 $\pm$ 11.3 | 69.4 $\pm$ 6.3  |
| Adam BOHB       | 2.0 $\pm$ 0.3     | 5.8 $\pm$ 1.2     | 19.9 $\pm$ 4.2 | 41.8 $\pm$ 7.8  | 84.0 $\pm$ 6.9  |
| Adam MFBO       | 5.4 $\pm$ 1.1     | 7.1 $\pm$ 1.0     | 12.7 $\pm$ 2.0 | 19.3 $\pm$ 3.5  | 67.7 $\pm$ 64.5 |
| Baseline DE     | 19.5 $\pm$ 2.7    | 33.2 $\pm$ 7.3    | —              | —               | —               |
| Optuna+DE       | 442.7 $\pm$ 886.7 | 84.2 $\pm$ 19.4   | —              | —               | —               |
| DE+DE Hybrid    | 2107 $\pm$ 2460   | 16650 $\pm$ 22785 | —              | —               | —               |

*Примечание.* Прочерки для DE на DIGITS, ABALONE и KIN8NM соответствуют пропуску прогонов: на этих наборах данных время работы у DE превышает разумный бюджет; данные качества (потеря, точность) для DE на этих задачах в таблицах 2, 3 получены без полного логирования времени.

Кривые сходимости методов на малых наборах данных с осью абсцисс в виде времени работы приведены на рисунке 2. Диаграмма показывает, что ПРО-методы класса А практически мгновенно достигают плато потерь (горизонтальная асимптота на уровне ниже 0.1), тогда как DE-методы продолжают медленно убывать в течение всего отведённого времени.




Рис. 2: Кривые сходимости (накопленный минимум валидационной потери в зависимости от времени работы) на малых наборах данных. Цветные ленты показывают  $\pm 1$  стандартное отклонение по 5 значениям начального состояния

Дополнительное наблюдение из рисунка 2: на WINE и WDBC видны характерные «обрезанные» левые края кривых для НРО-методов — это обусловлено тем, что финальный шаг (полное доучивание выбранной конфигурации) занимает значительное время относительно фазы поиска, и до его завершения метод формально не имеет точки на накопленной кривой. На DIGITS, ABALONE и KIN8NM, где время работы существенно больше, разница между кривыми проявляется яснее.

## 5.4 Результаты на больших задачах: Higgs и Fashion-MNIST

На больших задачах применялись только методы класса A; DE-методы не запускались по причинам, обсуждавшимся в разделе 4.8. Сводка тестовых потерь и точности представлена в таблице 5.

Таблица 5: Результаты на больших наборах данных (mean  $\pm$  std по 5 значениям начального состояния). Полужирным выделены лучшие результаты в столбце

| Метод           | Higgs                    |                          | Fashion-MNIST            |                          | Время работы, сек |            |
|-----------------|--------------------------|--------------------------|--------------------------|--------------------------|-------------------|------------|
|                 | потеря $\downarrow$      | точн. $\uparrow$         | потеря $\downarrow$      | точн. $\uparrow$         | Higgs             | F-MNIST    |
| Adam baseline   | <b>0.541</b> $\pm$ 0.002 | <b>0.723</b> $\pm$ 0.002 | 0.439 $\pm$ 0.147        | 0.883 $\pm$ 0.032        | <b>49.9</b>       | <b>236</b> |
| Случайный поиск | 0.567 $\pm$ 0.054        | 0.715 $\pm$ 0.010        | <b>0.291</b> $\pm$ 0.030 | 0.912 $\pm$ 0.007        | 178.0             | 897        |
| Adam+TPE        | 0.567 $\pm$ 0.023        | 0.716 $\pm$ 0.004        | 0.314 $\pm$ 0.032        | 0.905 $\pm$ 0.010        | 178.9             | 962        |
| Adam GP-BO      | 0.562 $\pm$ 0.011        | 0.713 $\pm$ 0.007        | 0.310 $\pm$ 0.063        | 0.909 $\pm$ 0.017        | 179.3             | 949        |
| Adam Hyperband  | 0.544 $\pm$ 0.005        | 0.721 $\pm$ 0.003        | 0.315 $\pm$ 0.050        | 0.911 $\pm$ 0.012        | 496.4             | 2731       |
| Adam BOHB       | 0.544 $\pm$ 0.003        | 0.721 $\pm$ 0.003        | 0.293 $\pm$ 0.031        | <b>0.913</b> $\pm$ 0.008 | 464.0             | 2404       |
| Adam MFBO       | 0.564 $\pm$ 0.009        | 0.710 $\pm$ 0.012        | 0.319 $\pm$ 0.010        | 0.900 $\pm$ 0.007        | 160.7             | 804        |

### 5.4.1 Анализ результатов на больших наборах данных

Картина на двух больших наборах данных принципиально различается, что само по себе является важным наблюдением.

На Higgs Adam baseline неожиданно лидирует по всем трём метрикам: потеря 0.541 (против 0.544–0.567 у методов класса A), точность 0.723 (против 0.710–0.721), время работы 50 секунд (против 161–496 у методов класса A). Все методы укладываются в полосу шириной 5% по потере и 1.5% по точности — то есть пространство гиперпараметров на этой задаче является «плоским»: при всех разумных значениях  $h$ ,  $lr$ , dropout модель сходится примерно к одному и тому же качеству. В таких условиях Adam baseline со значениями по умолчанию ( $h = 256$ ,  $lr = 10^{-3}$ , dropout = 0.2) случайно оказывается «не хуже среднего», причём он обучается одну сессию подряд 20 эпох, тогда как у методов класса A финальное обучение составляет 15 эпох.

На Fashion-MNIST преимущество дает не именно байесовский подход, а сам факт подбора гиперпараметров: методы НРО существенно стабилизируют качество

по сравнению с Adam baseline. Метод ВОНВ дает нам один из лучших результатов по качеству, тогда как MFBO является более быстрым и стабильным способом при ограниченном времени.

**Главный практический результат для MFBO:** метод не является лучшим подходом по итоговой потере, однако демонстрирует выгодный компромисс «качество/время». На задачах Higgs и Fashion-MNIST он показывает сравнимо близкое качество, имея время работы примерно в 3 раза меньше, чем Hyperband и ВОНВ.

## 5.5 Анализ кривых сходимости

В этом разделе кривые сходимости методов рассматриваются с трёх различных точек зрения: время работы, число оценок при максимальной верности и эпохи-эквиваленты. Каждая из осей отражает свою сторону вычислительной стоимости и позволяет увидеть аспекты, которые скрывает остальные две.

### 5.5.1 Сходимость по времени работы

Кривые сходимости по времени работы для всех шести наборов данных (5 малых + Higgs) представлены на рисунке 3.




Рис. 3: Кривые сходимости (накопленный минимум валидационной потери в зависимости от времени работы) на 6 наборах данных — 5 малых табличных и Higgs. Цветные ленты —  $\pm 1$  стандартное отклонение по 5 значениям начального состояния

Главное наблюдение из рисунка 3: на ABALONE, KIN8NM и Higgs все методы класса A сходятся к близким значениям потерь, и кривые становятся почти горизонтальными достаточно быстро. Adam baseline (синяя кривая) первым выходит на плато за счёт фиксированной конфигурации без затрат на поиск; остальные методы достигают того же плато с задержкой, соответствующей фазе поиска. Особенно показательно сравнение MFBO (розовая кривая) с Hyperband (фиолетовая) и ВОНВ (коричневая) на Higgs: MFBO выходит на плато в районе 160 секунд, тогда как Hyperband и ВОНВ продолжают работать до 460–500 секунд, не достигая существенно лучшего качества.

На WINE и WDBC видны выраженные «всплески» — это связано с тем, что для очень маленьких задач (124–400 объектов в обучающей выборке) валидационная потеря может принимать практически нулевые значения, и накопленный минимум показывает резкие падения, связанные с одиночными удачными точками.

### 5.5.2 Сходимость по числу оценок при максимальной верности

Рисунок 4 показывает кривые сходимости с осью абсцисс в виде числа оценок при максимальной верности.




Рис. 4: Кривые сходимости в зависимости от числа оценок при максимальной верности. Сплошные линии — методы, регулярно выполняющие оценки при разной верности (только MFBO); пунктирные — DE-методы. Остальные методы класса А на этой оси не отображаются: они засчитывают одну оценку при максимальной верности только в самом конце прогона

Эта ось менее информативна для общего сравнения, поскольку определение «оценки при максимальной верности» различается между методами:

- Для MFBO одна оценка соответствует обучению на одном из уровней верности (1, 5 или 20 эпох на малых задачах), и метод регулярно логирует точки на этой оси.
- Для остальных методов класса А (TPE, GP-BO, случайный поиск, Hyperband, BOHB) полное обучение проводится только на финальной фазе, поэтому формально на оси есть только одна точка в конце.
- Для DE-методов поколение засчитывается как одна оценка с эпохами-эквивалентами 1.0.

Из рисунка 4 видно, что MFBO на малых наборах данных в течение поиска выходит на хорошие значения примерно за 100–300 оценок при разной верности, что соответствует относительно малому числу оценок при максимальной верности. На Higgs MFBO выполняет порядка одной оценки при максимальной верности за весь прогон, продолжая работать в основном на пониженной верности.

### 5.5.3 Сходимость по эпохам-эквивалентам

Эта ось отражает суммарное число эпох обучения, выполненных методом, и является методологически наиболее однородной мерой бюджета между методами с различными механизмами оценки.

Из рисунка 5 следует:

- На WINE, WDBC и DIGITS все методы класса А сходятся к близким значениям менее чем за 100 эпох-эквивалентов.




Рис. 5: Кривые сходимости в зависимости от числа эпох-эквивалентов на 6 наборах данных. Эта мера отражает суммарное число пройденных по данным эпох и позволяет сравнить методы при сопоставимом совокупном бюджете обучения

- На ABALONE и KIN8NM плато достигается в районе 50–100 эпох-эквивалентов.
- На Higgs Adam baseline (20 эпох) находит свой результат в районе 20 эпох-эквивалентов; методы класса A с поиском продолжают улучшаться до 100–200 эпох-эквивалентов, не превосходя существенно baseline.

Эта ось показывает, что методы класса A не дают качественного выигрыша по **совокупному** числу эпох обучения относительно простого Adam baseline. Их преимущество — в выборе *какие именно* эпохи эффективнее распределить, а не в *общем числе* эпох.

#### 5.5.4 Сравнение DE и НРО на относительной шкале прогресса

Чтобы корректно сравнить методы с принципиально разными представлениями о бюджете (для DE одно поколение — одна точка траектории, для НРО — один trial), на рисунке 6 приведены кривые сходимости в зависимости от относительного прогресса прогона (от 0 до 100% выполненного бюджета).




Рис. 6: Кривые сходимости в относительной шкале прогресса (от 0 до 100% выполненного бюджета) на 5 малых наборах данных. Включает основные методы класса A (Adam baseline, Adam+TPE) и все методы класса B (Baseline DE, Optuna+DE, DE+DE Hybrid)

На рисунке 6 видно, что:

- На WINE и WDBC методы класса B (зелёная и красная кривые) в конечном итоге достигают значений потерь, сопоставимых с методами класса A, но проходят к ним в течение всего отведённого бюджета.

- На DIGITS, ABALONE и KIN8NM методы класса В остаются в значимо более высоких значениях потерь даже к концу прогона, что подтверждает наблюдение о невозможности эффективной оптимизации весов глубокой сети методом DE при данных размерах задач.
- Метод DE+DE Hybrid (фиолетовая кривая) на WINE и WDBC показывает раннее «застывание» на низком уровне потерь — это связано с особенностью внешнего DE по гиперпараметрам ( $h, F, Cr$ ), который быстро находит хорошую конфигурацию и далее тратит бюджет на её повторное подтверждение через внутренний DE.

## 5.6 Статистический анализ

Согласно рекомендациям [8] для сравнения методов на множестве задач, единицей анализа является **набор данных** (а не значение начального состояния), и применяется критерий Фридмана с пост-хок тестом Неме́нью.

Для всех 10 методов на 5 малых наборах данных критерий Фридмана даёт:

$$\chi^2 = 32.08, \quad p = 0.0002, \quad (12)$$

что свидетельствует о значимых различиях между методами на уровне  $\alpha = 0.05$ . Средние ранги (1 = лучший):

| Метод           | Средний ранг |
|-----------------|--------------|
| Adam baseline   | 3.0          |
| Adam TPE        | 3.0          |
| Случайный поиск | 3.4          |
| Adam GP-BO      | 3.6          |
| Adam Hyperband  | 4.0          |
| Adam BOHB       | 5.2          |
| Adam MFBO       | 6.0          |
| DE+DE Hybrid    | 8.6          |
| Optuna+DE       | 8.8          |
| Baseline DE     | 9.4          |

Critical Difference (CD) при  $\alpha = 0.05$  и  $N = 5$  задачах для  $k = 10$  методов составляет  $CD = 6.06$ . Критерий Фридмана показывает наличие значимых различий между методами. По post-hoc тесту Неме́нью статистически значима разница между лучшими методами класса А (ранг 3.0) и худшими методами класса В (ранг 9.4), при этом внутри класса А различия статистически не подтверждаются.

Critical Difference Diagram, иллюстрирующий ранжирование, представлен на рисунке 7. Соединительные горизонтальные отрезки указывают на группы методов, которые статистически неотличимы при  $\alpha = 0.05$ .




Рис. 7: Critical Difference Diagram для всех методов на 5 малых наборах данных. Соединительные линии указывают группы методов, которые статистически неотличимы при  $\alpha = 0.05$

Для 7 методов класса A на всех 6 наборах данных (5 малых + Higgs; Fashion-MNIST исключён, так как тип задачи существенно отличается от табличной) критерий Фридмана даёт:

$$\chi^2 = 7.21, \quad p = 0.30, \quad (13)$$

то есть на этом подмножестве **Н0 не отвергается**: статистически значимых различий между методами класса A нет. Это согласуется с наблюдением о том, что преимущество подбора гиперпараметров проявляется только в задачах с неоднородным ландшафтом качества (как Fashion-MNIST), а на пяти малых табличных и одной большой табличной задаче (Higgs) ландшафт оказывается достаточно плоским, чтобы все методы — включая Adam baseline — давали сопоставимые результаты.

## 5.7 Ограничения работы

При интерпретации полученных результатов следует учитывать следующие ограничения экспериментальной установки.

- **Объём набора данных Higgs.** Использовалась OpenML-версия с подвыборкой  $\approx 98\,000$  объектов вместо полной версии в 11 миллионов записей. Это снижает потенциальное преимущество многоуровневых методов, для которых полное обучение должно быть существенно дороже одноуровневой оценки.

- **Архитектура CNN.** Для Fashion-MNIST использовалась простая 3-блочная свёрточная сеть, а не современные архитектуры с residual-связями (ResNet) или вниманием (Transformer). Цель работы — сравнение методов оптимизации, а не достижение максимального качества на конкретной задаче.
- **Размерность пространства гиперпараметров.** Поиск проводился в трёхмерном пространстве ( $h$ ,  $lr$ ,  $dropout$ ). Поведение методов в высокоразмерных пространствах (10+ гиперпараметров, что характерно для современных программных комплексов с настройкой `optimizer/scheduler/augmentation`) может существенно отличаться.
- **Параметры DE.** Параметры эволюционных методов (размер популяции, число поколений) были уменьшены относительно типичных значений в литературе для возможности проведения экспериментов в разумный временной бюджет. Это могло снизить качество DE-методов; однако даже с увеличенными параметрами DE-методы остаются принципиально неэффективными для оптимизации весов глубоких сетей с большим числом параметров.



## 6 Выводы

По итогам экспериментального сравнения методов оптимизации можно сформулировать следующие основные выводы:

- На простых табличных задачах НРО не дает значимого выигрыша, то есть стандартные значения гиперпараметров Adam уже достаточно хороши.
- На Fashion-MNIST оптимизация гиперпараметров повышает стабильность, следовательно, НРО снижает дисперсию предсказаний и улучшает воспроизводимость эксперимента.
- MFBO полезен как эффективный по времени метод. Он не всегда лучший по потере, однако дает тройное ускорение относительно Hyperband/ВОНВ при сравнимом качестве.
- Дифференциальная эволюция в выбранном объеме вычислительных ресурсов плохо масштабируется, из чего следует, что DE как "black-box" оптимизация весов глубоких сетей неэффективна в рассматриваемом бюджете.

## 7 Заключение

Проведённое исследование подтвердило, что выбор метода оптимизации гиперпараметров не является нейтральным относительно задачи. Стандартное представление о том, что байесовские методы всегда превосходят простые альтернативы, верно лишь в определённых условиях — задачи с неоднородным ландшафтом качества и нетривиальной чувствительностью к выбору гиперпараметров. На простых задачах, где разумные значения гиперпараметров по умолчанию работают почти оптимально, дорогие методы поиска не оправдывают своих вычислительных затрат.

### Научная значимость

- Проведён корректный статистический анализ различий между методами с использованием критерия Фридмана и пост-хок теста Немея по наборам данных (как рекомендовано в работе [8]), а не по значениям начального состояния, что является более надёжной процедурой для сравнения методов на гетерогенных задачах.
- Эмпирически показано, что многоуровневый байесовский подход (MFBO) сохраняет преимущество по времени работы над bandit-методами (Hyperband, BOHB) при сравнимом качестве, что является эмпирическим подтверждением теоретических ожиданий, представленных в работе [6].
- Сформулированы практические рекомендации по выбору метода оптимизации в зависимости от вычислительной стоимости задачи и характера ландшафта качества.

### Практическая ценность

- На задаче Higgs многоуровневый байесовский подход (MFBO) демонстрирует ускорение в  $\sim 3$  раза относительно Hyperband и BOHB при сравнимом качестве (потеря 0.564 против 0.544, точность 0.710 против 0.721).
- На задаче Fashion-MNIST использование любого метода класса A (случайный поиск, TPE, GP-BO, Hyperband, BOHB, MFBO) повышает стабильность качества: стандартное отклонение по значениям начального состояния снижается с 0.147 (Adam baseline) до 0.030 (BOHB), что критично для воспроизводимости результатов в production-сценариях.

### Возможные направления продолжения исследования

- Расширение экспериментов на современные архитектуры (ResNet, Transformer) и задачи большего масштаба (ImageNet, Higgs в полном объёме);

- Trust-region варианты GP-BO для высокоразмерных пространств гиперпараметров (например, TuRBO [12]), применимых к настройке оптимизатора, scheduler и augmentation одновременно;
- Сравнение с DEHB (Evolutionary Hyperband) — гибридом DE и многоуровневого подхода, потенциально объединяющим преимущества обоих классов методов;
- Расширение пространства гиперпараметров до категориальных переменных (тип оптимизатора, выбор активации, тип нормализации), что приближает экспериментальную установку к реальным AutoML-задачам.

## Основной итог работы

Байесовская оптимизация гиперпараметров не является универсальным решением для максимизации качества моделей. Главное преимущество многоуровневых методов заключается в том, что они позволяют значительно быстрее находить приемлемые конфигурации на вычислительно сложных задачах. В то же время на простых задачах базовый алгоритм Adam со стандартными гиперпараметрами часто обеспечивает результат сопоставимого уровня, не требуя дополнительных затрат на поиск.

## Список литературы

- [1] J. Snoek, H. Larochelle, R. P. Adams. *Practical Bayesian Optimization of Machine Learning Algorithms*. Advances in Neural Information Processing Systems (NeurIPS), 2012.
- [2] J. Bergstra, R. Bardenet, Y. Bengio, B. Kégl. *Algorithms for Hyper-Parameter Optimization*. NeurIPS, 2011.
- [3] J. Bergstra, Y. Bengio. *Random Search for Hyper-Parameter Optimization*. Journal of Machine Learning Research, 13:281–305, 2012.
- [4] L. Li, K. Jamieson, G. DeSalvo, A. Rostamizadeh, A. Talwalkar. *Hyperband: A Novel Bandit-Based Approach to Hyperparameter Optimization*. Journal of Machine Learning Research, 18(185):1–52, 2017.
- [5] S. Falkner, A. Klein, F. Hutter. *BOHB: Robust and Efficient Hyperparameter Optimization at Scale*. Proc. ICML, 2018.
- [6] J. Wu, S. Toscano-Palmerin, P. I. Frazier, A. G. Wilson. *Practical Multi-fidelity Bayesian Optimization for Hyperparameter Tuning*. Proc. UAI, 2019.

- [7] A. Klein, S. Falkner, S. Bartels, P. Hennig, F. Hutter. *Fast Bayesian Optimization of Machine Learning Hyperparameters on Large Datasets*. Proc. AISTATS, 2017.
- [8] J. Demšar. *Statistical Comparisons of Classifiers over Multiple Data Sets*. Journal of Machine Learning Research, 7:1–30, 2006.
- [9] R. Storn, K. Price. *Differential Evolution — A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces*. Journal of Global Optimization, 11(4):341–359, 1997.
- [10] T. Akiba, S. Sano, T. Yanase, T. Ohta, M. Koyama. *Optuna: A Next-generation Hyperparameter Optimization Framework*. Proc. KDD, 2019.
- [11] M. Balandat, B. Karrer, D. R. Jiang, S. Daulton, B. Letham, A. G. Wilson, E. Bakshy. *BoTorch: A Framework for Efficient Monte-Carlo Bayesian Optimization*. NeurIPS, 2020.
- [12] D. Eriksson, M. Pearce, J. Gardner, R. D. Turner, M. Poloczek. *Scalable Global Optimization via Local Bayesian Optimization*. NeurIPS, 2019.
- [13] D. P. Kingma, J. Ba. *Adam: A Method for Stochastic Optimization*. Proc. ICLR, 2015.
- [14] H. Xiao, K. Rasul, R. Vollgraf. *Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms*. arXiv:1708.07747, 2017.
- [15] P. Baldi, P. Sadowski, D. Whiteson. *Searching for Exotic Particles in High-energy Physics with Deep Learning*. Nature Communications, 5:4308, 2014.